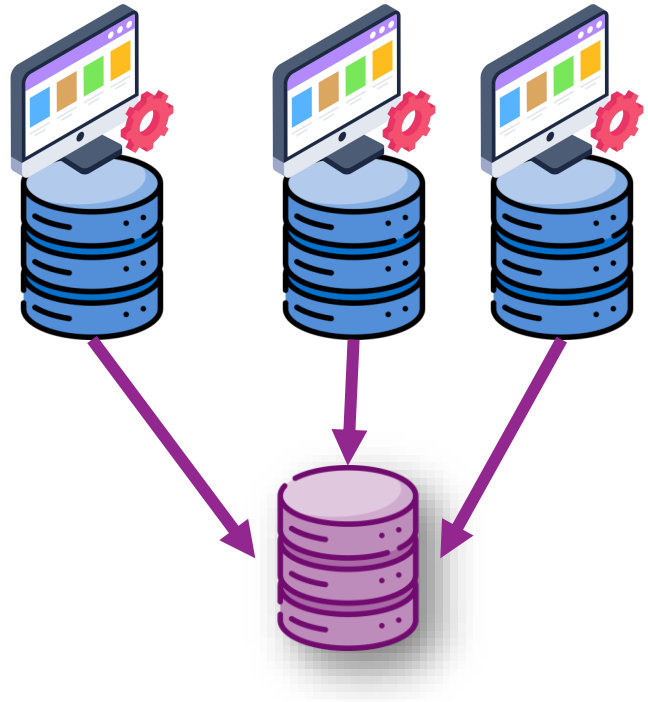
Datawarehouses

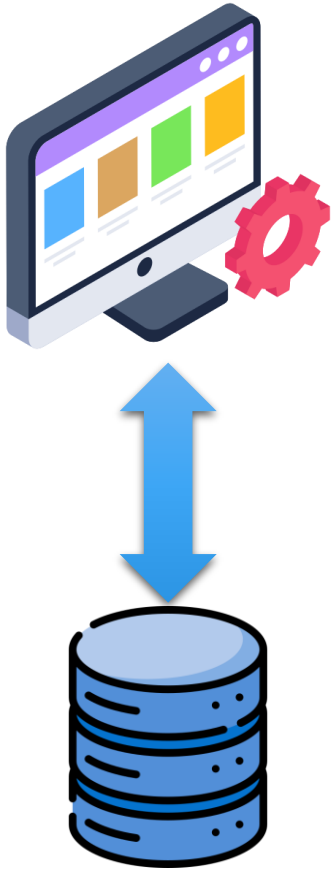
- Introducción y Deficiencias de los Sistemas Transaccionales
- Sistemas Transaccionales vs. Data Warehouse
- Procesos que conforman un Data Warehouse
- Metodología de Diseño y Dimensiones
- Metadata



Sistemas Transaccionales (OLTP - On-Line Transaction Processing)

Características principales:

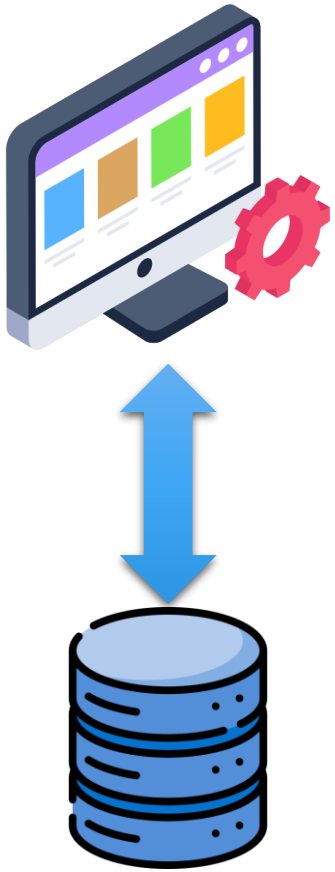
- Registrar y respaldar la operación diaria del negocio.
- Operaciones habituales sobre la base de datos son INSERT, UPDATE, DELETE de alta frecuencia.
- Altamente **normalizado (3FN)** para evitar duplicación y garantizar integridad.
- Sus datos guardan el estado **actual** de la información y transacciones rápidas.



Sistemas Transaccionales (OLTP - On-Line Transaction Processing)

¿Por qué NO consultar la base de datos operacional para analítica?

- **Bloqueo y Rendimiento:** Consultas pesadas congelan las operaciones de la empresa.
- **Pérdida de Historial:** Los datos se actualizan/sobrescriben (solo muestran la 'foto de hoy').
- **Silos de Información:** Datos fragmentados en múltiples sistemas, formatos y bases heterogéneas.
- **Complejidad Estructural:** Demasiadas uniones (JOINs) ralentizan el tiempo de respuesta.



Data Warehouse
(OLAP - On-Line Analytical Processing)

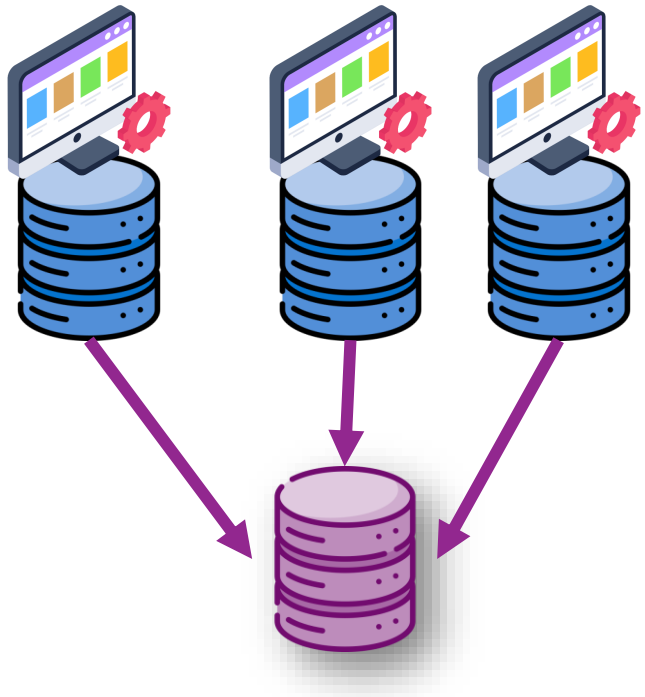
Un Data Warehouse (almacenamiento de datos) ***es un repositorio de información recopilada de múltiples fuentes, almacenada bajo un esquema unificado y que reside en un único sitio***. Una vez recopilados, los datos se almacenan durante mucho tiempo, lo que permite a los usuarios acceder a datos históricos.



Data Warehouse
(OLAP - On-Line Analytical Processing)

Características principales:

- **Múltiples fuentes heterogéneas:** Integra información dispersa en distintas bases de datos de la empresa.
- **Esquema unificado y repositorio central:** Homogeneiza formatos, estructuras y códigos bajo un solo modelo.
- **Perspectiva histórica prolongada:** Conserva los datos a lo largo de los años para análisis de tendencias (a diferencia de los sistemas operacionales que solo ven el estado actual).
- **Soporte a la Toma de Decisiones:** Diseñado exclusivamente para consultas analíticas y generación de informes de negocio.

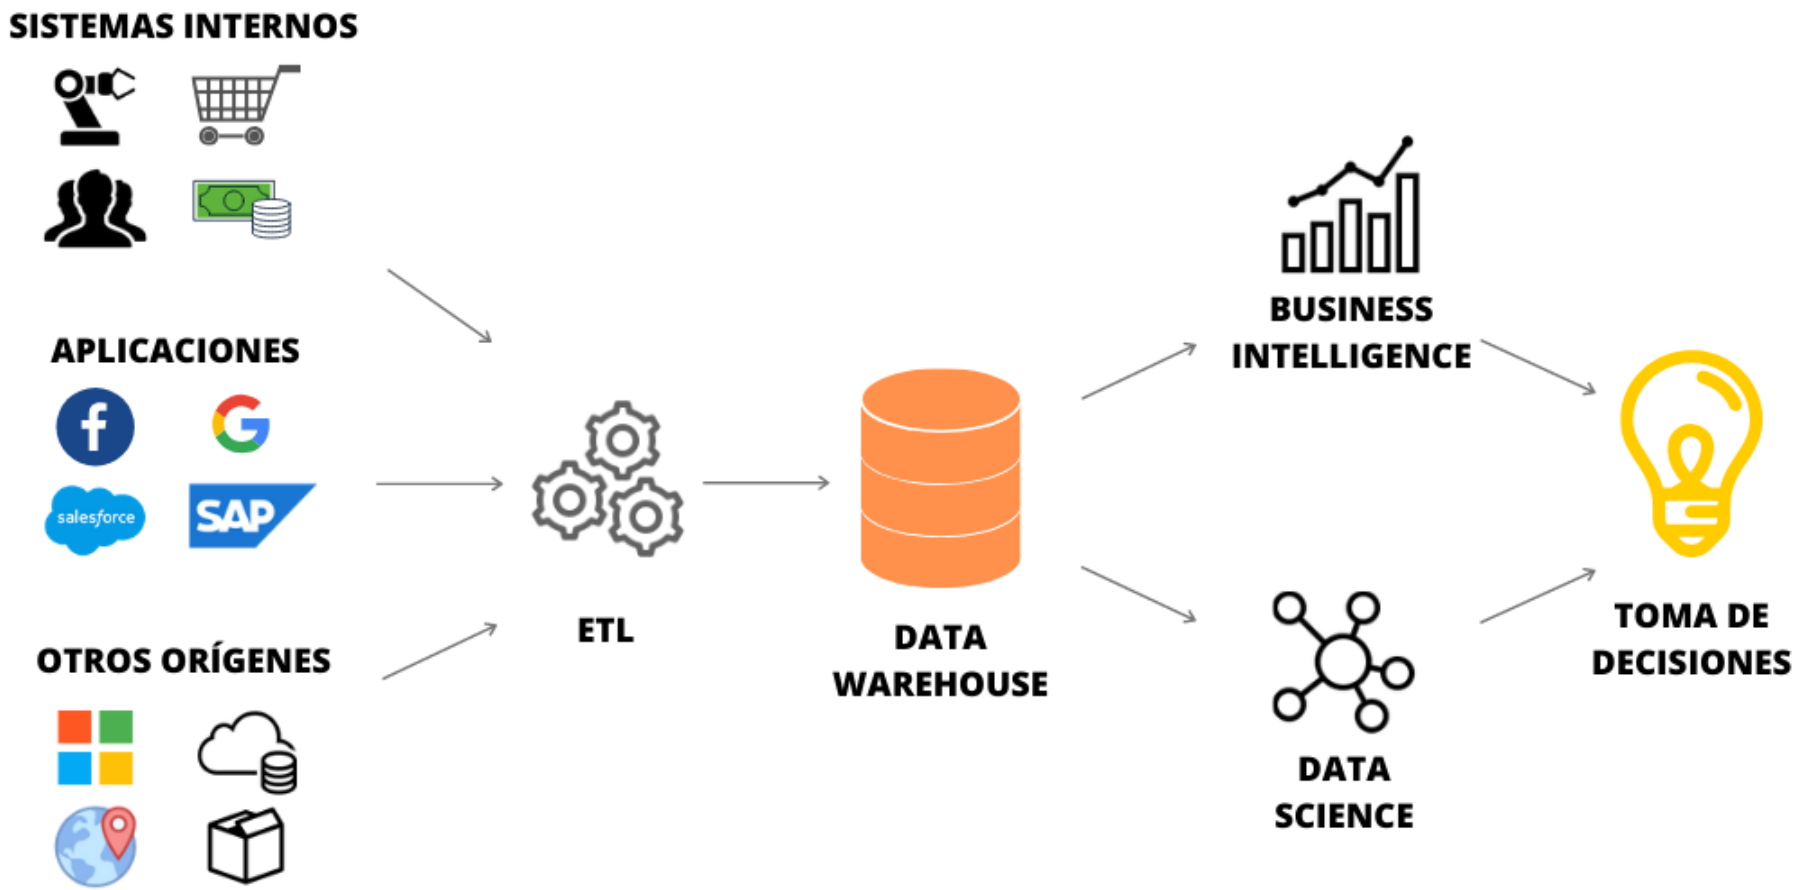


Sistemas Transaccionales vs. Data Warehouse

Criterio	Sistemas Transaccionales (OLTP)	Data Warehouse (OLAP)
Enfoque	Operacional (Día a día)	Analítico (Toma de decisiones)
Operaciones	Lectura y Escritura rápida (CRUD)	Solo Lectura (Consultas complejas)
Tiempo	Datos actuales / Tiempo real	Datos históricos y consolidados
Estructura	Normalizado (3FN - Múltiples tablas)	Desnormalizado (Pocas tablas)
Orientación	Orientado a la Aplicación	Orientado a Temas de Negocio

Un error común es pensar que un Data Warehouse es simplemente una base de datos grande. En realidad, es un **sistema integrado de procesos** que captura **datos dispersos y los transforma en conocimiento útil para la empresa**

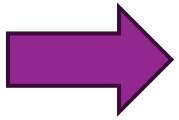
Arquitectura Clásica

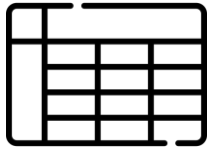


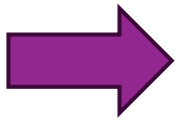
Proceso ETL

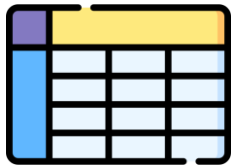












Extraccion

Captura periódica de datos desde fuentes heterogéneas.

Transformacion

Staging Area

- **Limpieza:** Tratamiento de nulos, inconsistencias y duplicados.
- **Homogeneización:** Unificación de formatos (ej. monedas, fechas)
- **Enriquecimiento:** Generación de métricas derivadas.

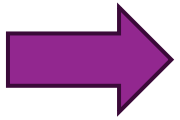
Carga

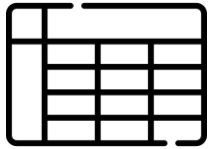
Inserción masiva de los datos procesados en las tablas del Data Warehouse.

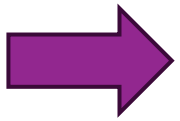
Proceso ETL

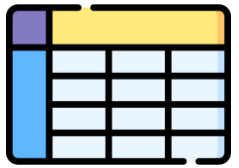












Extraccion

- Orquestadores que descargan los datos y los insertan en un dataset especifico

Transformacion

- Procesos que curan los datos (stored procedures) de la staging area

Carga

- Procesos que insertan en un nuevo dataset los datos procesados

Metodología de Diseño

Los 4 Pasos de Ralph Kimball

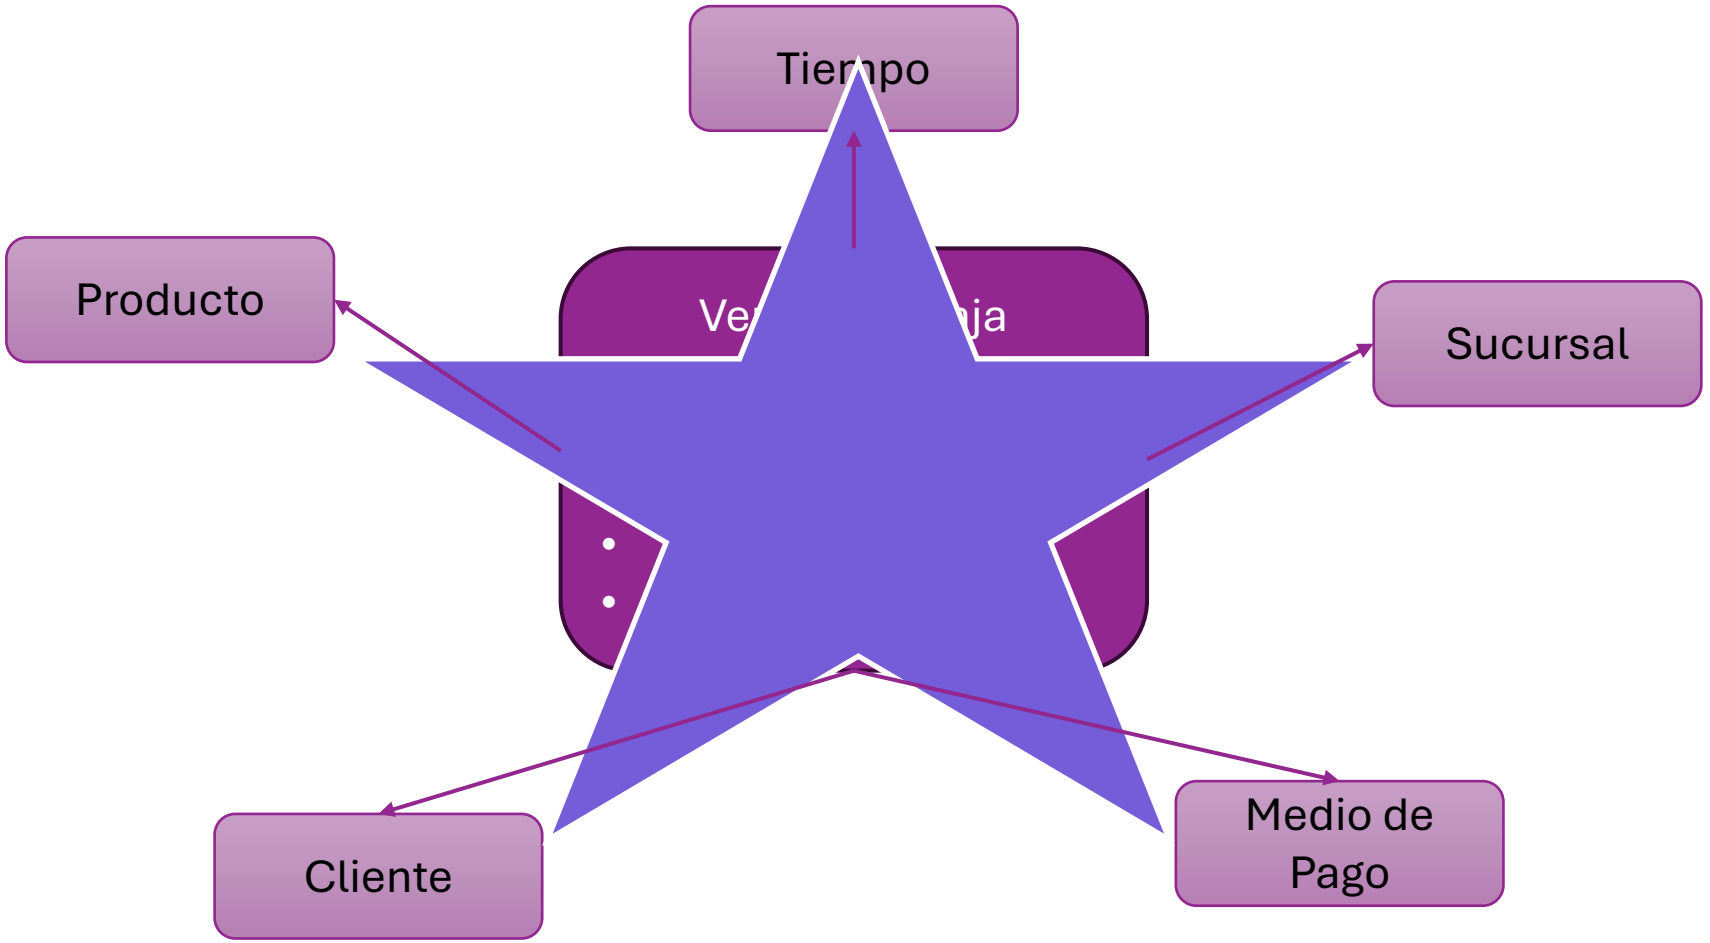
Diseño Multidimensional

- **Seleccionar el Proceso de Negocio:** Definir el área analítica a modelar (ej. *Ventas*, *Facturación*, *Envíos*).
- **Definir el detalle:** Establecer el nivel mínimo de detalle de cada registro (¿Qué representa exactamente UNA sola fila de mi tabla principal?)
- **Identificar las Dimensiones:** Definir el contexto del evento (*¿Quién?, ¿Dónde?, ¿Cuándo?, ¿Qué?*).
- **Identificar los Hechos:** Definir las métricas cuantitativas medibles (*Monto total, Unidades vendidas, Costo*).

- **¿Cuándo se vendió?** ➔ Dimensión **Tiempo / Fecha** *(año, mes, día, hora, si es feriado o fin de semana)*.
- Cantidad_Vendida *(ejemplo: 2 unidades)*.
- Precio_Unitario *(ejemplo: $1.500)*.
- Monto_Total_Venta *(ejemplo: $3.000)*.
- Monto_Descuento *(ejemplo: $300 por promo)*.
- Costo_Producto *(ejemplo: $2.100, para calcular la ganancia neta)*.
- **¿Cómo pagó?** ➔ Dimensión **Medio de Pago** *(efectivo, tarjeta de crédito, billetera virtual)*.

Metodología de Diseño

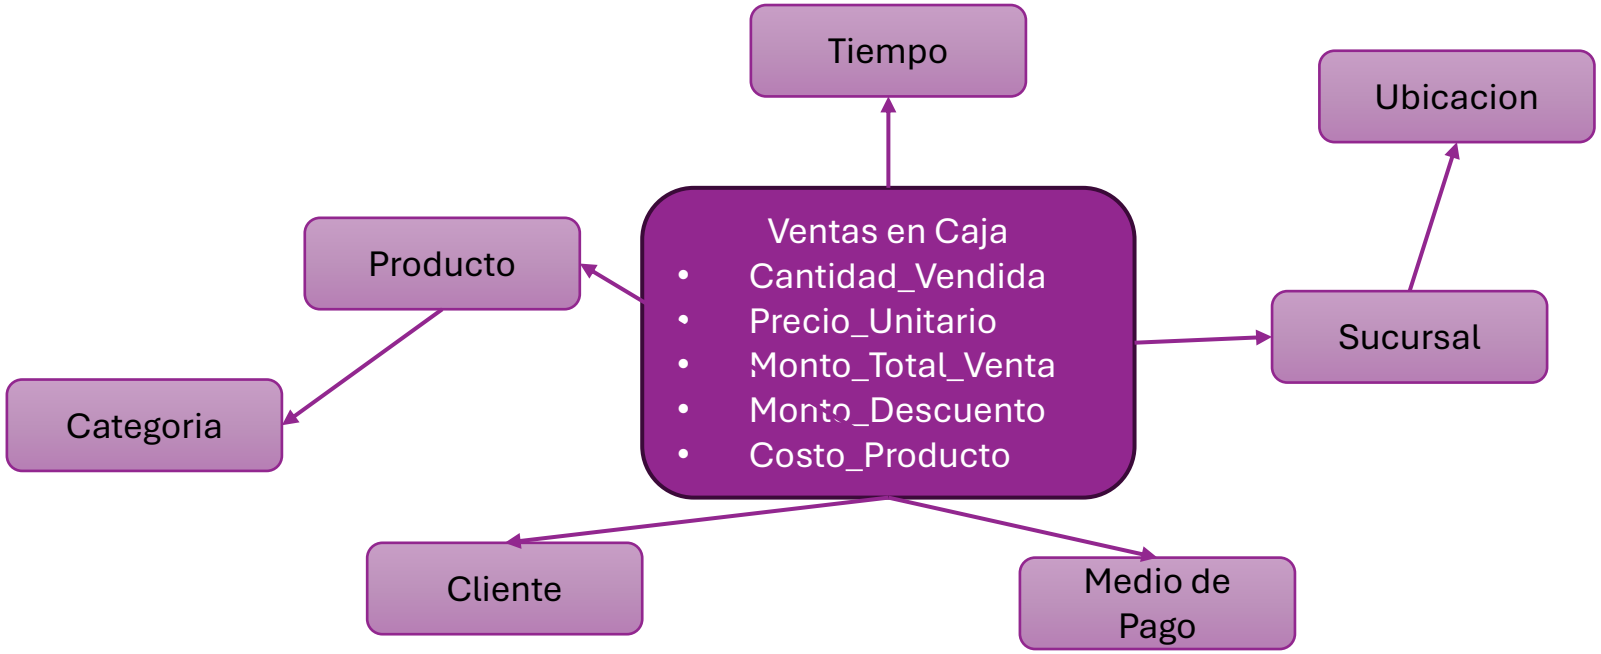
Diseño Multidimensional



Diseño desnormalizado

Metodología de Diseño

Diseño Copo de Nieve



- Evolución del esquema en estrella donde las **dimensiones se normalizan** (3FN).
- Las dimensiones con jerarquías se dividen en múltiples sub-tablas relacionadas.

Metodología de Diseño

¿Cuál de los dos esquemas conviene usar?



- El **Copo de Nieve** ahorra espacio en disco porque no repite textos. Pero para saber cuánto vendimos en la categoría 'Lácteos', la consulta SQL va a tener que hacer un JOIN de la Tabla de Hechos con Producto, otro JOIN con Subcategoría y otro JOIN con Categoría.



- En el **Esquema en Estrella**, como la categoría está metida adentro de Producto, resolvemos todo con **un solo JOIN**.

El almacenamiento en disco hoy en día es baratísimo; lo que es realmente caro es el tiempo de espera del usuario analizando datos. En la mayoría de los casos se prefiere **el Esquema en Estrella**, priorizando la velocidad de lectura por sobre la normalización.

Metadatos

Manual y Mapa del datawarehouse

'¿De qué tabla y columna de producción vino esta métrica?', *'¿A qué hora corrió el ETL anoche?'* o *'¿Falló algún proceso de carga?'*.

- **Dos Grandes Categorías de Metadata:**
  - **Metadata Técnica:** Tipos de datos, nombres de tablas, linaje del dato (*Data Lineage* - mapa origen a destino), logs de ejecución de procesos ETL, frecuencia de actualización.
  - **Metadata de Negocio:** Diccionario de datos, definiciones conceptuales, reglas de negocio (ej. *'Fórmula exacta de Venta Neta'*, *'Criterio para definir Cliente Activo'*).

¿De qué nos sirve tener documentada la metadata si nadie la respeta?
Y ahí es exactamente donde nace el **Gobierno de Datos**.

Situacion: La reunión del Comité Ejecutivo

Entran a la sala el **Gerente de Marketing** y el **Gerente de Finanzas**.

El Gerente de Marketing muestra un gráfico y dice: *'Este mes ganamos 1.000 clientes nuevos'*.

El Gerente de Finanzas salta y dice: *'¡Imposible! Según mi reporte solo entraron 600'*.

Situacion: La reunión del Comité Ejecutivo

Para Marketing, un 'Cliente Nuevo' es cualquiera que dejó su email en la página web.

Para Finanzas, un 'Cliente Nuevo' es solo aquel que ya pagó su primera factura.

Ambos extrajeron datos del mismo Data Warehouse, pero **usaron reglas de negocio distintas**. Resultado: una hora de reunión perdida discutiendo *quién tiene la razón* en lugar de tomar decisiones.

Gobierno de Datos

¿Para qué existe el Gobierno de Datos?
El Gobierno de Datos existe para evitar ese caos. Es el marco institucional que define **políticas, roles y estándares**:

1. **Crea la 'Única Verdad' (*Single Source of Truth*):** Dictamina una definición oficial y obligatoria para cada término de negocio (ej. *'A partir de hoy, la métrica Cliente Activo se calcula formalmente de esta manera'*).

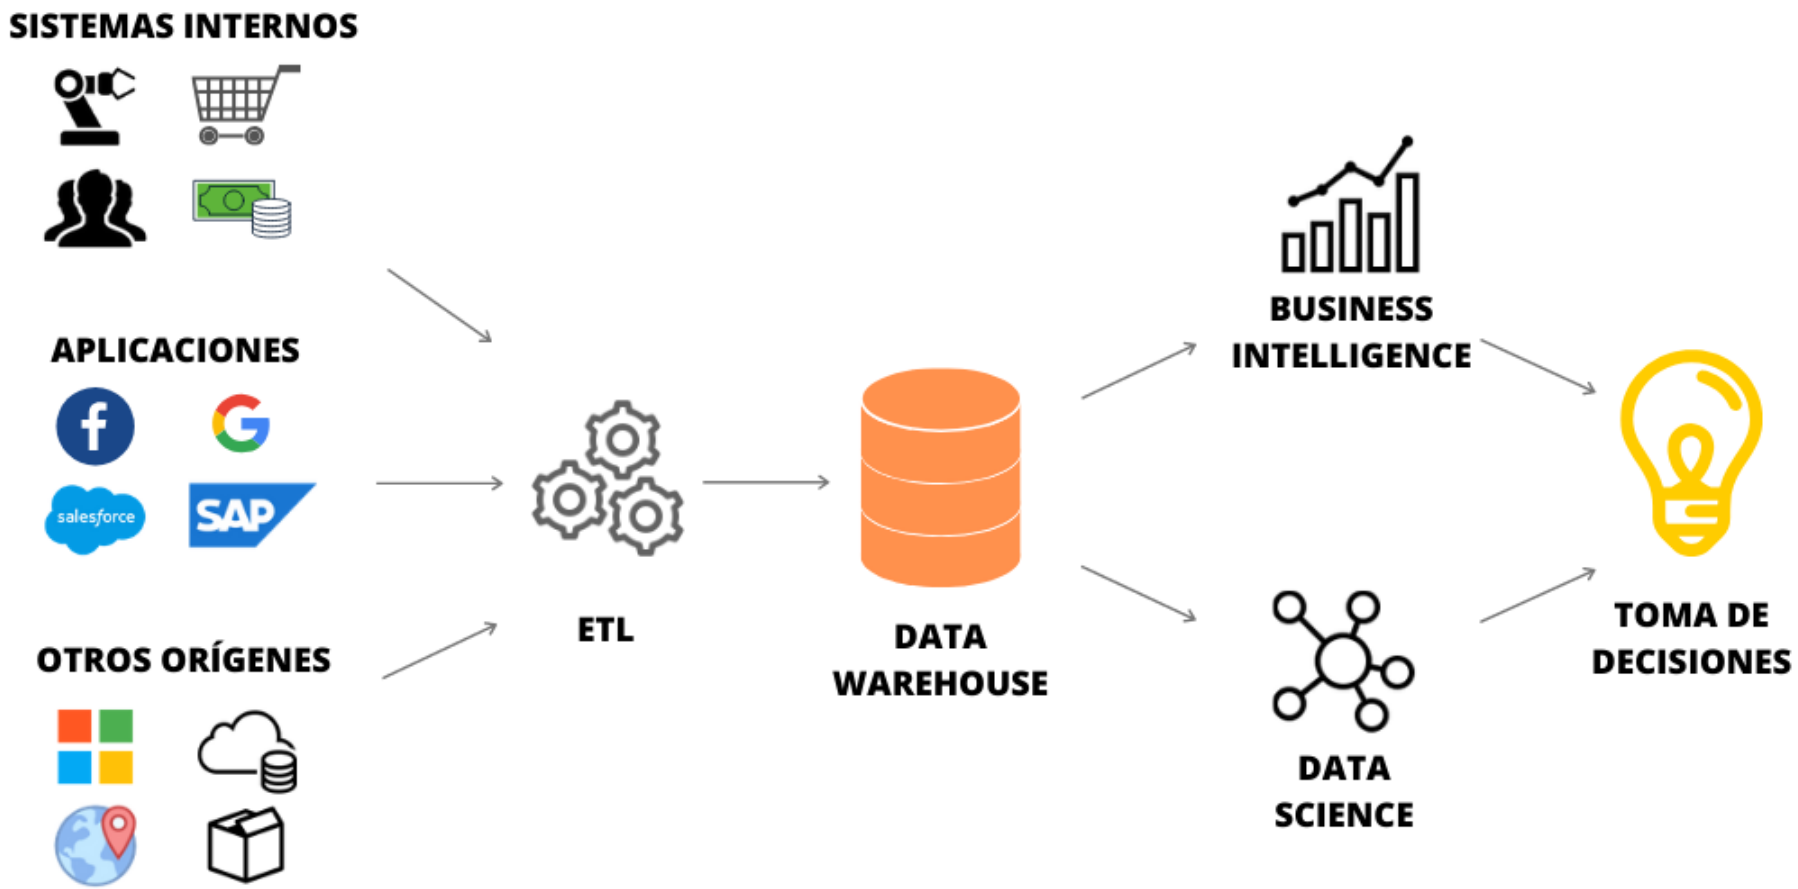
2. **Asigna Responsabilidades:** Define figuras como el *Data Owner* (dueño del dato) y el *Data Steward* (custodio de la calidad del dato). Si los datos de clientes vienen mal desde la sucursal, hay un responsable directo asignado para corregir el proceso.

3. **Garantiza Seguridad y Privacidad:** Define quién tiene permiso para ver qué datos (cumplimiento de leyes de protección de datos personales, datos sensibles de tarjetas, etc.).

Gobierno de Datos

Metadata es el *catálogo/mapa* (el conocimiento).
Gobierno de Datos es el *reglamento y la autoridad* (quién decide, supervisa y garantiza ese conocimiento).

¿Al Gerente General de Comercial le importa la consulta SQL o el proceso ETL anoche?


SISTEMAS INTERNOS
APLICACIONES
salesforce
SAP
OTROS ORÍGENES
ETL
DATA WAREHOUSE
BUSINESS INTELLIGENCE
DATA SCIENCE
TOMA DE DECISIONES

Explotación de Datos



¿Qué es la Capa de Explotación?

- La interfaz final entre la infraestructura técnica del Data Warehouse y los usuarios de negocio.
- La etapa donde el dato procesado se convierte en **información útil y acción estratégica**.

Principales Formas de Explotación:

- **Dashboards e Informes Ejecutivos:** Tableros visuales interactivos (Power BI, Tableau, Looker).
- **Self-Service BI y Consultas Ad-Hoc:** Capacidad del usuario para explorar, filtrar y armar sus propios reportes sin depender de Sistemas.
- **Analítica Avanzada y Ciencia de Datos:** Modelos predictivos, Machine Learning y Data Mining sobre el Data Warehouse.

El Objetivo: Democratizar el acceso a la información y lograr una cultura *Data-Driven*.

Power BI

- Conectando la Base de Datos

